


- **因果关系定义 (RCM和SCM框架下)**：改变一变量会引起另一变量的变化（可能不被观测，但改变概率分布），除上述因果关系定义外，其他对因果的理解通常都不被视为真正的因果。
 - **因果性判断**：需改变目标变量的产生机制
 - **相关性判断**：不需改变系统，判断 $P(X | Y) = P(X)$ 是否成立
 - **格兰杰因果**：刻画引入一个变量是否对另一变量的预测有促进作用
- **因果推断定义**：求解一对或多对变量是否存在因果关系以及因果效应强度的任务，包括因果发现和因果效应估计。
- **伪相关性**：具备统计意义上相关性，却不符合客观因果规律的情况。
- **X与Y具备相关性的三种情况**：


$X \longrightarrow Y$

$X \longleftarrow Y$

直接因果关系



X与Y相关



Z给定时，X与Y相关

- **单元 (Unit)** : 干预效果研究中的**最小研究对象**。潜在结果框架下, 不同时间点的单元不同, 数据集中的**一个单元**是整个随机变量对应的样本, 术语“样本”和“单元”可互换使用。
- **变量 (Variables)** : 一般指**干预前变量** (pre-treatment variables), 其指不受干预影响的变量, 如性别, 年龄; **干预后变量** (post-treatment variables) 指受干预影响的变量。
- **干预 (Intervention)** : 也叫**介入**, 干预变量 $Z = 1$ 的单元为**处理组**, $Z = 0$ 的单元为**对照组**。
- **混杂因素 (Confounders)** : 对1对变量同时产生影响的因素。
- **潜在结果 (Potential outcome)** : 包含**观测结果**和**反事实结果**。
- **倾向得分 (Propensity score)** : $e(X_i) = P(Z_i = 1 | X_i)$, 反映样本 X_i 选择treatment的概率。

Why causality



東南大學
SOUTHEAST UNIVERSITY

□ 模型分类角度：因果模型在所有模型中的地位

模型分类表

Model	Predict in i.i.d. setting	Predict under distr. shift/intervention	Answer counter-factual questions	Obtain physical insight	Learn from data
Mechanistic/physical	yes	yes	yes	yes	?
Structural causal	yes	yes	yes	?	?
Causal graphical	yes	yes	no	?	?
Statistical	yes	no	no	no	yes

统计模型

低级

数据驱动

因果模型

回答干预，反事实

数据驱动，弱假设

微分方程模型

高级

专家经验

因果模型结合了统计和微分方程模型各自优势


Why causality




東南大學
SOUTHEAST UNIVERSITY

□ 所用数据角度：2种分类

- **非结构化数据：** 更难让计算机理解，不直接体现因果信息



Audio



Image

Four scores and seven
years ago...

Text

- **结构化数据：** 存储在数据库中，由二维表结构表达，可能部分对应于因果图中变量

User Age	Ad Id	...	Click
41	93242		1
80	93287		0
18	87312		1
⋮	⋮		⋮
27	71244		1

统计模型： 基于结构和非结构化数据，i.i.d.

因果模型： 基于结构化数据



因果表征学习

Why causality



东南大学
SOUTHEAST UNIVERSITY

□ 若干悖论：Simpson悖论、替代指标悖论、新生儿体重悖论

➤ Simpson悖论：总体统计结果与每一个子部分统计结果相反 Sure-thing Principle

记录是否服药的700例患者痊愈率

患者	服药时治愈率	未服药时治愈率
男性患者	93% (81/87)	87% (234/270)
女性患者	73% (192/263)	69% (55/80)
合计	78% (273/350)	83% (289/350)
因果	83.20%	78.18%

$$P(Y|X, Z=0)$$

$$P(Y|X, Z=1)$$

$$P(Y|X) = \sum_z P[Y|X, z] P(z|X)$$

$$P[Y|do(X)] = \sum_z P[Y|X, z] P(z)$$

• 统计框架下的计算：


$$\frac{87}{350} (0.93) + \frac{263}{350} (0.73) = 0.78$$
$$\frac{270}{350} (0.87) + \frac{80}{350} (0.69) = 0.83$$

} 实验组和对照组权重不同

• 因果框架下的计算：

$$\frac{357}{700} (0.93) + \frac{343}{700} (0.73) = 0.832$$
$$\frac{357}{700} (0.87) + \frac{343}{700} (0.69) = 0.7818$$

} 实验组和对照组权重一致



因果框架下，实验组和对照组可比

□ **模型背景：** 现实很多统计问题，由于成本、风险和伦理问题，数据不能来自RCT，需要从观察性研究中**估计因果效应**（因果推断领域重点问题）。

□ **模型描述：** X_i ：个体 i 是否吸烟； Y_i ：个体 i 是否得肺癌； Z_i ：混杂因素。

➤ 当满足**条件可忽略性**，**ACE可识别**：

$$ACE = E(Y(1)) - E(Y(0))$$

$$= E[E(Y(1) \mid Z)] - E[E(Y(0) \mid Z)]$$

$$= E[E(Y(1) \mid Z, X = 1)] - E[E(Y(0) \mid Z, X = 0)]$$

$$= E[E(Y \mid Z, X = 1)] - E[E(Y \mid Z, X = 0)]$$

全期望公式

条件可忽略性 $X \perp \{Y(1), Y(0)\} \mid Z$

一致性原则：

若 $X = x, Y = y$, 则 $Y_x = y$

➤ 内曼潜在结果模型中ACE：

$$ACE = E(Y(1)) - E(Y(0))$$

$$= E(Y(1) \mid X = 1) - E(Y(0) \mid X = 0)$$

$$= E(Y \mid X = 1) - E(Y \mid X = 0)$$

RCT中可忽略性成立 $X \perp \{Y(1), Y(0)\}$

一致性原则

可忽略性下，通过观测数据，估计ACE

□ POM优缺点:



- 优：对先验知识要求低，应用广泛。
- 缺：可忽略性无法被观测数据验证，数学结果无保证；混杂因素需可观测。



□ SCM包括：因果图，结构化方程，干预和反事实

- **因果图**：使用有向非循环图（DAG）描述变量之间关系，若节点间存在连边，则父节点是**因**，子节点是**果**。只有**箭头一致**的边才产生因果效应。
- **因子分解定理**：对于 $X = (X_1, \dots, X_p)$ 构成的DAG， pa_j 为 X_j 的父节点，联合分布可分解成：

$$P(X) = \prod_{j=1}^p P(X_j \mid pa_j)$$




$$\begin{aligned} P(X) = & P(X_1) \cdot P(X_2 \mid X_1, X_3) \cdot P(X_3) \\ & \cdot P(X_4 \mid X_3) \cdot P(X_5 \mid X_1, X_4) \cdot \\ & \cdot P(X_6 \mid X_5) \cdot P(X_7 \mid X_3, X_4, X_6) \end{aligned}$$

结构因果模型-因果图




- 三种条件独立性:




链结构

$$X \perp Z \mid Y$$



分叉结构

$$Y \perp Z \mid X$$




对撞结构

$$X \perp Z$$

当对撞节点或其后代被观测, X 与 Z 相关

- d分离:** 若 Z 阻断 X 到 Y 间的所有路径 (不管方向), 则称 Z d分离 X 和 Y , 记为 $(X \perp Y \mid Z)_G$.

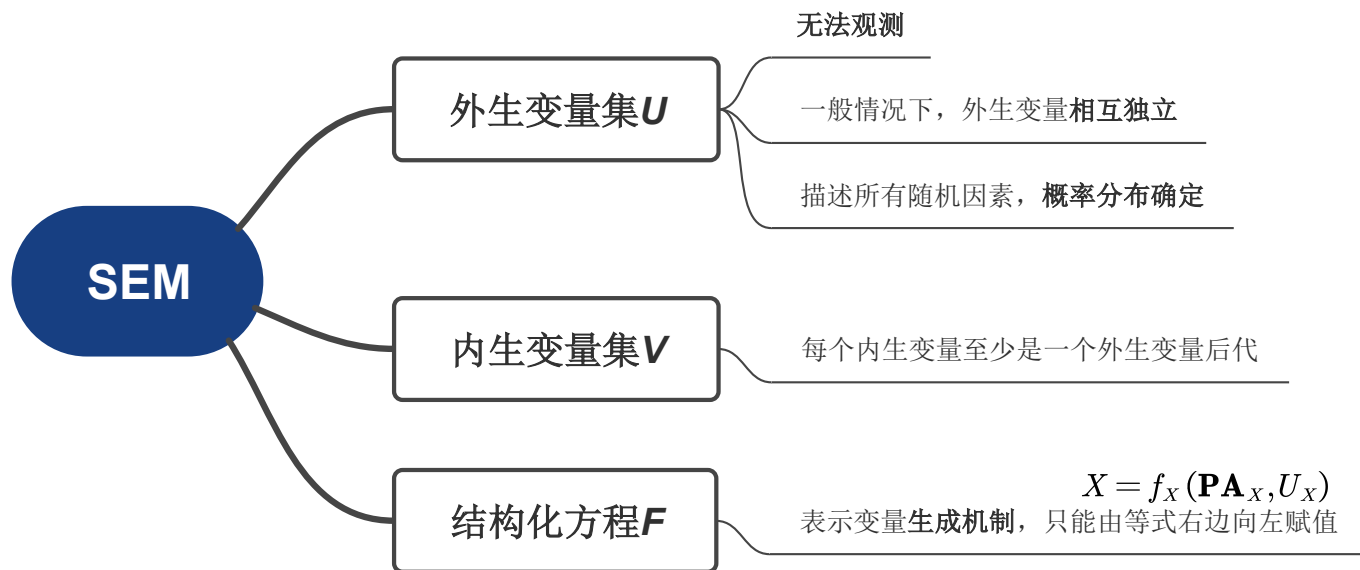
$$\begin{cases} X \perp Y \mid Z \\ X \perp Y \end{cases} \implies (X \perp Y \mid Z)_G$$



结构因果模型-结构方程模型



东南大学
SOUTHEAST UNIVERSITY





$$V = \{X, Y, Z\}, U = \{U_X, U_Y, U_Z\}, F = \{f_X, f_Y, f_Z\}$$

$$f_X : X = U_X$$

$$f_Y : Y = \frac{x}{4} + U_Y$$

$$f_Z : Z = \frac{y}{12} + U_Z$$

SEM定量




因果图定性

□ **干预**：改变目标变量产生机制，维持其余**机制不变**的操作。

➤ **干预前后联合分布间关系：**

$$P(X_1 = x_1, \dots, X_p = x_p \mid \text{do}(X_j = x'_j)) = \frac{P(X_1 = x_1, \dots, X_p = x_p)}{P(X_j = x_j \mid \text{pa}_j)} I(x_j = x'_j)$$



对应



新DAG：删除**原DAG**指向 X_j 的边，强制 $X_j = x'_j$



对应

原DAG

➤ **SCM中由do算子定义ACE**：研究 X_5 对 X_7 的因果作用



$$ACE = E(X_7 \mid \text{do}(X_5 = 1)) - E(X_7 \mid \text{do}(X_5 = 0))$$

由联合分布求积分得边缘分布，估计ACE

结构因果模型-干预



东南大学
SOUTHEAST UNIVERSITY

➤ **后门准则:** 在DAG中, X 和 Y 是不相交节点子集, X_i 和 X_j 分别是 X 和 Y 中任意节点, 若变量集 Z 对任何变量有序对 (X_i, X_j) 满足如下条件:

- (1) Z 中没有 X_i 的后代节点。
- (2) Z 阻断 X_i 和 X_j 之间指向 X_i 的路径 (**后门路径**)。

则称 Z 满足 (X, Y) 的后门准则, 此时 X 对 Y 的因果作用**可识别**:

$$\begin{aligned} P(Y = y \mid \text{do}(X = x)) &= P_m(Y = y \mid X = x) \\ &= \sum_z P_m(Y = y \mid X = x, Z = z) P_m(Z = z \mid X = x) \\ &= \sum_z P_m(Y = y \mid X = x, Z = z) P_m(Z = z) \\ &= \sum_z P(Y = y \mid X = x, Z = z) P(Z = z) \end{aligned}$$

干预定义


全概率、条件概率

干预后, $X \perp Z$

两个不变性方程

X_4 满足 (X_5, X_7) 的后门准则

$$\begin{aligned} ACE &= E(X_7 \mid \text{do}(X_5 = 1)) - E(X_7 \mid \text{do}(X_5 = 0)) \\ &= \sum_{x_4} \{E(X_7 \mid X_4 = x_4, X_5 = 1) - E(X_7 \mid X_4 = x_4, X_5 = 0)\} P(X_4 = x_4) \end{aligned}$$



观测部分变量 (X_4, X_5, X_7), 估计ACE

➤ SCM和POM等价性:

do算子所得结果为“潜在结果”： $P\{Y \mid do(X) = x\} = P\{Y(x)\}$

结果一致 {

SCM: $ACE = E(Y \mid do(X = 1)) - E(Y \mid do(X = 0))$
 $= E[E(Y \mid Z, X = 1) - E(Y \mid Z, X = 0)]$

POM: $ACE = E(Y(1)) - E(Y(0))$
 $= E[E(Y(1) \mid Z)] - E[E(Y(0) \mid Z)]$
 $= E[E(Y(1) \mid Z, X = 1)] - E[E(Y(0) \mid Z, X = 0)]$
 $= E[E(Y \mid Z, X = 1)] - E[E(Y \mid Z, X = 0)]$


SCM后门准则和POM可忽略性下, ACE结果一致

结构因果模型-干预



➤ **前门准则：** 在DAG中，若变量集 Z 对 (X, Y) 满足如下条件：

- (1) Z 阻断所有从 X 到 Y 的**有向路径**。
- (2) 从 X 到 Z 的所有**后门路径**均被阻断。
- (3) X 阻断从 Z 到 Y 的**后门路径**。



则称 Z 满足 (X, Y) 的前门准则，此时若 $P(x, z) > 0$ ，则 X 对 Y 的因果作用**可识别**：

$$\begin{aligned} P(y | do(X) = x) &= \sum_u P(y | x, u) P(u) \\ &= \sum_u \sum_z P(y | x, z, u) P(z | x, u) P(u) \\ &= \sum_u \sum_z P(y | z, u) P(z | x) P(u) \\ &= \sum_z P(z | x) P(y | do(Z) = z) \\ &= \sum_z P(z | x) \sum_{x'} P(y | x', z) P(x') \end{aligned}$$

U 满足 (X, Y) 后门准则

全概率公式


$Z \perp U | X$ 且 $Y \perp X | (Z, U)$

U 满足 (Z, Y) 后门准则

X 满足 (Z, Y) 后门准则

⇓ X_6 满足 (X_5, X_7) 的前门准则

$$\begin{aligned} ACE &= E(X_7 | do(X_5 = 1)) - E(X_7 | do(X_5 = 0)) \\ &= \sum_{x_6} P(X_6 = x_6 | X_5 = 1) \sum_{x_5} P(X_7 = x_7 | X_5 = x_5, X_6 = x_6) P(X_5 = x_5) - \sum_{x_6} P(X_6 = x_6 | X_5 = 0) \sum_{x_5} P(X_7 = x_7 | X_5 = x_5, X_6 = x_6) P(X_5 = x_5) \end{aligned}$$




当混杂变量不可观测，观测 (X_5, X_6, X_7) ，估计ACE

□ **反事实：** 假定两次观测只有目标变量不同，其他外生变量取值和作用机制不变，直接反映因果关系。

➤ **反事实的图形化表示例子：**

A Toy Example



$$\begin{aligned} X &= U_X \\ H &= a \cdot X + U_H \\ Y &= b \cdot X + c \cdot H + U_Y \end{aligned}$$

Let us consider a student named Joe, for whom we measure $X = 0.5$, $H = 1$, and $Y = 1.5$. Suppose we wish to answer the following query: What would Joe's score have been had he doubled his study time?

$$\begin{aligned} U_X &= 0.5, \\ U_H &= 1 - 0.5 \cdot 0.5 = 0.75, \text{ and} \\ U_Y &= 1.5 - 0.7 \cdot 0.5 - 0.4 \cdot 1 = 0.75. \end{aligned}$$

$$E[Y_{H=2} \mid X=0.5, H=1, Y=1.5]$$

$$\begin{aligned} Y_{H=2}(U_X = 0.5, U_H = 0.75, U_Y = 0.75) \\ &= 0.5 \cdot 0.7 + 2.0 \cdot 0.4 + 0.75 \\ &= 1.90 \end{aligned}$$



(PRIMER, CH4)

结构因果模型-反事实




► **孪生网络：** 验证反事实下的条件独立性


验证: $Z_x \not\perp\!\!\!\perp X \mid Y$



真实世界



反事实世界




结构因果模型-反事实



➤ SCM中计算反事实的两套公理系统:

- **第一套公理系统:** 基于图, 通过do-Calculus计算
- **第二套公理系统:** 建立SCM与POM联系



Exclusion restrictions: For every variable Y having parents PA_Y and for every set of variables $Z \subset V$ disjoint of PA_Y , we have

$$Y_{pa_Y}(u) = Y_{pa_Y, z}(u).$$

Independence restrictions: If Z_1, \dots, Z_k is any set of nodes in V not connected to Y via paths containing only U variables, we have

$$Y_{pa_Y} \perp\!\!\!\perp \{Z_{1pa_{Z_1}}, \dots, Z_{kpa_{Z_k}}\}$$

Composition: For any three sets of endogenous variables X, Y , and W in a causal model, we have

$$W_x(u) = w \implies Y_{xw}(u) = Y_x(u).$$

Effectiveness: For all sets of variables X and W , we have

$$X_{xw}(u) = x.$$

将图中所有条件独立性变为POM中的假设, 比孪生网络更简单。

将关于反事实变量问题转为观测变量问题。

➤ 第二套公理系统推导前门准则:

Step1: 写出所有节点的父节点

$$PA_X = \{\emptyset\}, PA_Z = \{X\}, PA_Y = \{Z\}$$


Step2: 根据独立性和条件性约束写出POM中假设

$$Z_x(u) = Z_{yx}(u)$$

$$X_y(u) = X_{zy}(u) = X_z(u) = X(u),$$

$$Y_z(u) = Y_{zx}(u)$$

$$Z_x \perp\!\!\!\perp \{Y_z, X\}$$



Step3: 计算 $P(Z_x = z), P(Y_z = y)$

$$P(Z_x = z) = P(Z_x = z \mid x) \quad \text{条件独立性}$$

$$= P(Z = z \mid x) \quad \text{合成性}$$

$$P(Y_z = y) = \sum_x P(Y_z = y \mid x) P(x) \quad \text{全概率}$$

$$= \sum_x P(Y_z = y \mid x, Z_x = z) P(x) \quad \text{条件独立性}$$

$$= \sum_x P(Y_z = y \mid x, z) P(x) \quad \text{合成性}$$

$$= \sum_x P(Y = y \mid x, z) P(x) \quad \text{合成性}$$

Step4: 计算 $P(Y_x = y)$

$$\begin{aligned} P(Y_x = y) &= \sum_z P(Z_x = z) P(Y_z = y) \\ &= \sum_z P(z \mid x) \sum_{x'} P(y \mid x', z) P(x') \end{aligned}$$

POM与SCM对比



东南大学
SOUTHEAST UNIVERSITY

□ POM:

- 用概率表示因果关系，所有条件独立性只是假设（形而上学），无法验证假设是否成立。
- 所有假设通过概率表示，再通过概率论推理进行因果效应估计。
- 反事实变量 Y_x 与观测变量 X 和 Y 通过一致性原则转换：**若 $X = x, Y = y$, 则 $Y_x = y$**
缺点：反事实结果无法超出观测结果
- 将 $Y|do(x)$ 视为 Y_x ，只有反事实概念
- 无法证明完备：POM中对于任意的反事实查询，不知道怎样给出完备的假设，使一定能从观测数据中计算。
- POM和SCM在表达性方面等价，但SCM有图的优势（实用性强：可直接验证条件独立性）

“Logic void of representation is metaphysics.”

-Judea Pearl

□ SCM:

- 用因果图表示因果关系，所有条件独立性来自因果图，方便验证假设。