


# Rescore研究背景与意义



東南大學  
SOUTHEAST UNIVERSITY




$$A := \varepsilon_A \sim U(-2, 2)$$


$$B := \frac{1}{2} A + \varepsilon_B \sim \begin{cases} N(0, 1), & P_1 \\ N(0, 0.1), & P_2 \end{cases}$$

$$C := 2B + \varepsilon_C \sim N(0, 1)$$


NOTEARS



SHD = 0




SHD = 1




SHD = 2


NOTEARS  
+ ReScore



SHD = 0



SHD = 0



SHD = 1

$P_1 = 1, P_2 = 0$

同质性

$P_1 = 0.2, P_2 = 0.8$

异质性

$P_1 = 0, P_2 = 1$

同质性

## □ 当前基于可微因果发现的2个缺点：

- 某些情况结构学习准确性低，**线性系统中链结构**容易被 NOTEARS 错误识别 (Reisach et al., NIPS'21)
- **异质数据**中，NOTEARS 很容易学到冗余因果关系。当前解决异质性的方法依赖于域注释的先验 (DICD, CD-NOD (Huang et al., JMLR'20))

## □ 可微CD失败原因（生成模型视角理解）：

- 收集的数据集自然包括**大量的简单**样本和**少量**可能包含**关键因果信息**的样本，**平均评分函数**无法反映样本重要性（Shrivastava et al., CVPR'16）

## □ 实验证明ReScore自适应学习样本权重：

- NOTEARS-MLP+ReScore应用于Sachs数据集（9组），学习样本权重
- 每组随机消除500样本，运行NOTEARS-MLP，得到相应SHD和TPR。随着组重要性增加，结果影响越大

Table 5: Performance comparison for removing samples in different groups

Group Index	3	5	7	1	2	6	4	8	0
Avg. ranking	578.4	2856.7	3368.1	3877.0	3949.4	4549.4	4573.2	4590.6	4910.1
SHD w/o group	16	16	17	16	16	17	17	19	19
TPR w/o group	0.529	0.412	0.412	0.412	0.412	0.412	0.412	0.353	0.294

**不同重要性样本自然存在于真实数据集中，ReScore能提取这种重要性**

## □ 双层优化:

$$\min_{\mathcal{G}} S_{\mathbf{w}^*}(\mathcal{G}; \mathbf{X}) + \mathcal{P}_{DAG}(\mathcal{G}),$$

$$\text{s.t. } \mathbf{w}^* \in \arg \max_{\mathbf{w} \in \mathbb{C}(\tau)} S_{\mathbf{w}}(\mathcal{G}; \mathbf{X}),$$

**自适应学习样本权重:** 在 $\mathcal{G}$ 给定情况下, 大量简单样本的loss值小, 少量关键样本的loss值大, 通过评分函数最大化, 简单样本学习得到较小的权重, 关键样本学习得到较大的权重。

where  $\mathbb{C}(\tau) := \{\mathbf{w} : 0 < \frac{\tau}{n} \leq w_1, \dots, w_n \leq \frac{1}{\tau n}, \sum_{i=1}^n w_i = 1\}$  for the cutoff threshold  $\tau \in (0, 1)$

$\tau \rightarrow 1$ 时, 权重分布趋于均匀分布。  $\tau \rightarrow 0$ 时, 权重分布可以更大地偏离均匀分布

## ➤ 重加权评分函数:

$$S_{\mathbf{w}}(\mathcal{G}; \mathbf{X}) = \mathcal{L}_{\mathbf{w}}(\mathcal{G}; \mathbf{X}) + \lambda \mathcal{R}_{\text{sparse}}(\mathcal{G}) = \sum_{i=1}^n w_i l(\mathbf{x}_i, f(\mathbf{x}_i)) + \lambda \mathcal{R}_{\text{sparse}}(\mathcal{G}),$$

## ➤ DAG约束:

$$\mathcal{P}_{DAG}(\mathcal{G}) = \alpha_t h(\mathcal{G}) + \frac{\mu_t}{2} |h(\mathcal{G})|^2$$

## ➤ 稀疏性约束: L1和L2正则化

通过最大化评分函数自适应学习样本权重

## Algorithm 1 ReScore Algorithm for Differentiable Score-based Causal Discovery

**Input:** observational data  $\mathcal{D}$ :  $\{\mathbf{x}_i : i = 1, 2, \dots, n\}$ , DAG learner parameters  $\theta_{\mathcal{G}}$ , reweighting model parameters  $\theta_w$ , cutoff threshold  $\tau$ , epoch to start reweighting  $K_{reweight}$ , maximum epoch in the inner loop  $K_{inner}$ , maximum epoch in the outer loop  $K_{outer}$

**Initialize:** initialize  $\theta_w$  to uniformly output  $\frac{1}{n}$ ,  $k_1 = 0$ ,  $k_2 = 0$

**for**  $k_1 \leq K_{outer}$  **do**

Fix reweighting model parameters  $\theta_w$

Calculate  $\mathbf{w}^*$  by applying threshold  $[\frac{\tau}{n}, \frac{1}{n\tau}]$

Optimize  $\theta_{\mathcal{G}}$  by minimizing  $S_{\mathbf{w}^*}(\mathcal{G}; \mathbf{X}) + \mathcal{P}_{DAG}(\mathcal{G})$  # Outer optimization in Equation 6

**if**  $k_1 \geq k_{reweight}$  **then**

**for**  $k_2 \leq K_{inner}$  **do**

Fix the DAG learner's parameters  $\theta_{\mathcal{G}}$

Get  $\mathbf{w}$  from  $\theta_w$  by applying threshold  $[\frac{\tau}{n}, \frac{1}{n\tau}]$

Optimize  $\theta_w$  by maximizing  $S_{\mathbf{w}}(\mathcal{G}; \mathbf{X})$  # Inner optimization in Equation 6

$k_2 \leftarrow k_2 + 1$

**end for**

$k_1 \leftarrow k_1 + 1$

$k_2 \leftarrow 0$

**end if**

**end for**

**return** predicted  $\mathcal{G}$  from DAG learner

**外循环（生成器）：**通过内循环确定的样本权重来优化DAG学习器，进一步提升CD性能

**内循环（判别器）：**通过NN学习样本权重，输入为各样本残差，输出为各样本权重

交替训练内外循环，根据DAG学习器误差学习样本权重

# 实验结果-合成数据实验配置



东南大学  
SOUTHEAST UNIVERSITY

- **图类型:** ER或SF
- **节点个数:** 10、20、50
- **图密度:** 节点平均度数为2或4
- **函数形式:** 线性高斯等方差（噪声项服从标准正态）、非线性高斯过程  
( $f_i$ 服从高斯过程, 噪声项服从标准正态)

$$X_i = f_i(X_{pa(i)}) + N_i, i = 1, \dots, d$$

## □ 评估指标:

- **FDR:**  $(R + FP)/P$
- **TPR:**  $TP/T$
- **SID:** 衡量干预分布差异
- **SHD:** 估计DAG转为真实DAG所需添加、删除和反转边的总数。衡量图结构差异

$p$ :预测DAG边数

$R$ :预测DAG中反转边数

$FP$ :预测DAG中不在真实DAG无向骨架中的边数

$T$ :真实DAG边集数

$TP$ :预测DAG中预测正确的边数

# 实验结果-合成数据



東南大學  
SOUTHEAST UNIVERSITY

## □ 线性+非线性、10+50节点数、ER2+ER4:

Table 1: Results for ER graphs of 10 nodes on linear and nonlinear synthetic datasets.

	ER2				ER4			
	TPR $\uparrow$	FDR $\downarrow$	SHD $\downarrow$	SID $\downarrow$	TPR $\uparrow$	FDR $\downarrow$	SHD $\downarrow$	SID $\downarrow$
Random	0.08 $\pm$ 0.07	0.93 $\pm$ 0.18	33.2 $\pm$ 7.3	95.6 $\pm$ 12.2	0.09 $\pm$ 0.17	0.93 $\pm$ 0.09	52.3 $\pm$ 16.7	80.3 $\pm$ 17.7
NOTEARS	0.85 $\pm$ 0.09	<b>0.07</b> $\pm$ 0.07	5.8 $\pm$ 2.2	20.8 $\pm$ 5.2	0.79 $\pm$ 0.11	0.09 $\pm$ 0.05	10.0 $\pm$ 5.2	25.8 $\pm$ 9.9
+ ReScore	<b>0.89</b> $\pm$ 0.07 <sup>+5%</sup>	0.08 $\pm$ 0.09 <sup>-12%</sup>	<b>4.6</b> $\pm$ 2.3 <sup>+26%</sup>	12.8 $\pm$ 7.0 <sup>+63%</sup>	<b>0.85</b> $\pm$ 0.04 <sup>+8%</sup>	<b>0.05</b> $\pm$ 0.04 <sup>+57%</sup>	<b>7.2</b> $\pm$ 1.9 <sup>+39%</sup>	<b>24.2</b> $\pm$ 8.4 <sup>+7%</sup>
GOLEM	0.87 $\pm$ 0.06	0.22 $\pm$ 0.11	6.5 $\pm$ 3.4	13.0 $\pm$ 6.7	0.63 $\pm$ 0.03	0.16 $\pm$ 0.03	17.2 $\pm$ 1.3	48.0 $\pm$ 13.3
+ ReScore	0.88 $\pm$ 0.06 <sup>+1%</sup>	0.21 $\pm$ 0.11 <sup>+2%</sup>	6.0 $\pm$ 3.4 <sup>+8%</sup>	<b>12.4</b> $\pm$ 6.3 <sup>+5%</sup>	0.66 $\pm$ 0.04 <sup>+5%</sup>	0.17 $\pm$ 0.01 <sup>-5%</sup>	16.2 $\pm$ 1.0 <sup>+6%</sup>	46.7 $\pm$ 13.3 <sup>+3%</sup>
NOTEARS-MLP	0.76 $\pm$ 0.17	0.14 $\pm$ 0.09	7.0 $\pm$ 3.5	17.9 $\pm$ 10.0	0.83 $\pm$ 0.05	0.21 $\pm$ 0.04	10.9 $\pm$ 1.9	28.6 $\pm$ 12.0
+ ReScore	0.73 $\pm$ 0.07 <sup>-4%</sup>	0.10 $\pm$ 0.09 <sup>+37%</sup>	6.8 $\pm$ 2.9 <sup>+3%</sup>	20.3 $\pm$ 9.7 <sup>-11%</sup>	0.94 $\pm$ 0.06 <sup>+14%</sup>	0.15 $\pm$ 0.06 <sup>+44%</sup>	6.80 $\pm$ 2.7 <sup>+60%</sup>	8.80 $\pm$ 12.4 <sup>+225%</sup>
GraN-DAG	0.88 $\pm$ 0.06	0.02 $\pm$ 0.03	2.7 $\pm$ 1.6	8.70 $\pm$ 4.8	0.98 $\pm$ 0.02	0.12 $\pm$ 0.03	5.4 $\pm$ 1.1	3.70 $\pm$ 4.71
+ ReScore	<b>0.90</b> $\pm$ 0.05 <sup>+2%</sup>	<b>0.01</b> $\pm$ 0.03 <sup>+35%</sup>	<b>2.4</b> $\pm$ 1.1 <sup>+13%</sup>	<b>7.20</b> $\pm$ 3.0 <sup>+21%</sup>	<b>0.99</b> $\pm$ 0.01 <sup>+1%</sup>	<b>0.11</b> $\pm$ 0.01 <sup>+12%</sup>	<b>4.80</b> $\pm$ 0.6 <sup>+13%</sup>	<b>0.50</b> $\pm$ 0.81 <sup>+640%</sup>

Table 9: Results for ER graphs of 50 nodes on linear and nonlinear synthetic datasets.

	ER2				ER4			
	TPR $\uparrow$	FDR $\downarrow$	SHD $\downarrow$	SID $\downarrow$	TPR $\uparrow$	FDR $\downarrow$	SHD $\downarrow$	SID $\downarrow$
Random	0.04 $\pm$ 0.02	0.90 $\pm$ 0.03	397.3 $\pm$ 12.7	1082.0 $\pm$ 182.2	0.09 $\pm$ 0.08	0.92 $\pm$ 0.08	998.2 $\pm$ 45.9	3399.1 $\pm$ 489.2
NOTEARS	0.79 $\pm$ 0.06	<b>0.09</b> $\pm$ 0.03	27.6 $\pm$ 7.7	427.0 $\pm$ 186.1	0.51 $\pm$ 0.12	<b>0.27</b> $\pm$ 0.10	133.4 $\pm$ 29.5	1643.8 $\pm$ 172.2
+ ReScore	<b>0.88</b> $\pm$ 0.06 <sup>+11%</sup>	0.15 $\pm$ 0.04 <sup>-39%</sup>	<b>26.2</b> $\pm$ 7.6 <sup>+5%</sup>	<b>266.0</b> $\pm$ 146.4 <sup>+61%</sup>	<b>0.52</b> $\pm$ 0.21 <sup>+3%</sup>	0.29 $\pm$ 0.07 <sup>-7%</sup>	<b>130.2</b> $\pm$ 37.4 <sup>+2%</sup>	<b>1453.6</b> $\pm$ 336.5 <sup>+13%</sup>
GOLEM	0.80 $\pm$ 0.09	0.35 $\pm$ 0.09	68.6 $\pm$ 19.7	433.5 $\pm$ 215.6	0.31 $\pm$ 0.11	0.68 $\pm$ 0.06	150.6 $\pm$ 25.1	1775.4 $\pm$ 161.6
+ ReScore	0.82 $\pm$ 0.15 <sup>+3%</sup>	0.33 $\pm$ 0.14 <sup>+5%</sup>	63.4 $\pm$ 27.9 <sup>+8%</sup>	430.2 $\pm$ 155.5 <sup>+1%</sup>	0.39 $\pm$ 0.06 <sup>+24%</sup>	0.66 $\pm$ 0.06 <sup>+3%</sup>	146.3 $\pm$ 26.3 <sup>+3%</sup>	1643.6 $\pm$ 114.8 <sup>+8%</sup>
NOTEARS-MLP	0.32 $\pm$ 0.04	0.13 $\pm$ 0.08	69.5 $\pm$ 4.7	884.4 $\pm$ 172.8	0.17 $\pm$ 0.02	<b>0.06</b> $\pm$ 0.04	167.0 $\pm$ 4.1	1607.6 $\pm$ 97.0
+ ReScore	0.51 $\pm$ 0.08 <sup>+59%</sup>	<b>0.10</b> $\pm$ 0.07 <sup>+30%</sup>	53.5 $\pm$ 8.7 <sup>+30%</sup>	628.1 $\pm$ 120.6 <sup>+41%</sup>	0.26 $\pm$ 0.04 <sup>+52%</sup>	0.11 $\pm$ 0.05 <sup>-51%</sup>	154.4 $\pm$ 6.4 <sup>+8%</sup>	1437.7 $\pm$ 111.1 <sup>+12%</sup>
GraN-DAG	0.52 $\pm$ 0.09	0.15 $\pm$ 0.05	51.6 $\pm$ 9.3	632.8 $\pm$ 140.3	<b>0.32</b> $\pm$ 0.04	0.08 $\pm$ 0.16	141.6 $\pm$ 8.2	1379.0 $\pm$ 91.3
+ ReScore	<b>0.53</b> $\pm$ 0.06 <sup>+3%</sup>	0.11 $\pm$ 0.02 <sup>+36%</sup>	<b>46.0</b> $\pm$ 6.0 <sup>+12%</sup>	<b>581.0</b> $\pm$ 104.7 <sup>+9%</sup>	0.31 $\pm$ 0.03 <sup>-4%</sup>	0.06 $\pm$ 0.04 <sup>+32%</sup>	<b>138.8</b> $\pm$ 7.5 <sup>+2%</sup>	<b>1351.0</b> $\pm$ 98.2 <sup>+2%</sup>

ReScore能提升可微CD性能，取得SOTA结果

[Zhang A, Liu F, Ma W, et al. Boosting Differentiable Causal Discovery via Adaptive Sample Reweighting. In ICLR, 2023.]

# 实验结果-超参数影响




東南大學  
SOUTHEAST UNIVERSITY


## 研究自适应权重学习模型中隐藏层神经元数对ReScore影响：

### 实验配置：


- 10节点，ER4，非线性高斯过程，样本数600+2000。
- 隐藏层神经元数：1, 10, 20, 50, 80, 100




(a) TPR *w.r.t.* neurons



(b) FDR *w.r.t.* neurons



(c) SHD *w.r.t.* neurons



(d) SID *w.r.t.* neurons

Figure 5: Performance with varying neurons in ReScore model.

**ReScore对隐藏层神经元数量不敏感；样本量越大，性能越好**




# 实验结果-超参数影响



東南大學  
SOUTHEAST UNIVERSITY

□ 研究阈值 $\tau$ 对ReScore的影响:  $n = 2000, d = 20, ER4, GP$ 模型



(b) SHD *w.r.t.* threshold  $\tau$

不同实验设置下，最佳阈值通常在[0.7,0.99]内




# 实验结果-超参数影响



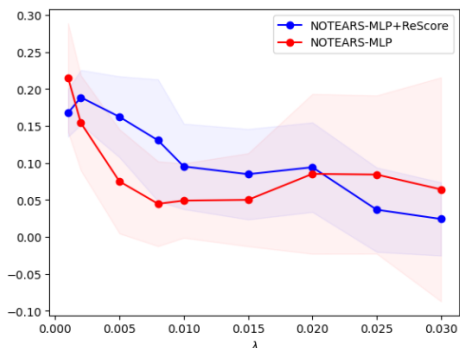
東南大學  
SOUTHEAST UNIVERSITY

## 研究L1正则化系数对ReScore影响:

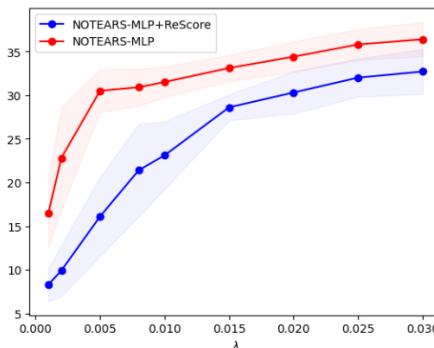
实验配置: 10节点, ER4, 非线性




(a) TPR *w.r.t.*  $\lambda$



(b) FDR *w.r.t.*  $\lambda$




(c) SHD *w.r.t.*  $\lambda$




(d) SID *w.r.t.*  $\lambda$

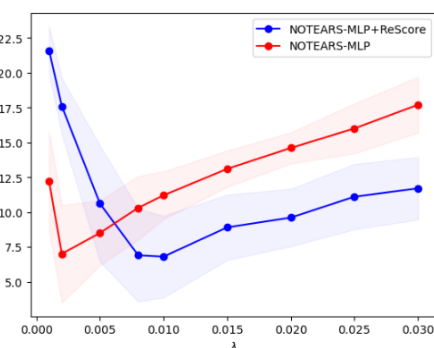
实验配置: 10节点, ER2, 非线性




(a) TPR *w.r.t.*  $\lambda$



(b) FDR *w.r.t.*  $\lambda$



(c) SHD *w.r.t.*  $\lambda$



(d) SID *w.r.t.*  $\lambda$

# 实验结果-真实异质数据Sachs



東南大學  
SOUTHEAST UNIVERSITY

Table 3: The performance comparison on Sachs dataset.

	TPR $\uparrow$	FDR $\downarrow$	SHD $\downarrow$	SID $\downarrow$	#Predicted Edges
Random	0.076	0.899	23	63	22
GOLEM + ReScore	0.176	0.026	15	53	4
	0.294	0.063	<b>14</b>	49	6
NOTEARS-MLP + ReScore	0.412	0.632	16	45	19
	0.412	0.500	<b>13</b>	43	14
GraN-DAG + ReScore	0.294	0.643	16	60	14
	0.353	0.600	<b>15</b>	58	15
GES + ReScore	0.294	0.853	31	54	34
	0.588	0.722	<b>28</b>	50	36
CD-NOD	0.588	0.444	15	-	18

ReScore能加强可微CD在真实异质数据Sachs上的性能

[Zhang A, Liu F, Ma W, et al. Boosting Differentiable Causal Discovery via Adaptive Sample Reweighting. In ICLR, 2023.]